

Rib Segmentation in Chest X-ray Images

一、介紹

肋骨骨折或病變是胸部 X 光常見的診斷重點，但人工標記耗時且易受主觀影響。為解決此問題，本專案開發一個能精確分割胸部 X 光中肋骨區域的深度學習模型，輔助醫療診斷並提升分析效率。

訓練資料介紹


本次使用資料集是一份小影像資料集。


影像總數：196 張影像為訓練集，49 張影像為訓練集。

影像原始大小：影像的原始大小範圍為：1864x2144 到 3320x3408 像素，並且所有影像均包含 4 個通道。

二、實驗流程

(1)模型訓練流程





流程說明:

(1) 資料準備與前處理

將原始資料集依 80/20 比例分為訓練集 (Train) 與驗證集 (Validation)。

訓練集處理：

- 尺寸調整：統一縮放至 512x512 像素。
- 資料擴增 (Augmentation)：包含隨機水平翻轉 (強制模型不再依賴肋骨出現在畫面中央，而是學會識別肋骨的紋理與結構)、銳利化處理 (模型能學會在邊界模糊的情況下，依然鎖定肋骨邊緣)、亮度與對比度隨機調整 (提升模型的臨床通用性)。
- 隨機裁剪至 480x480，並搭配動態填充 (Dynamic Padding) 回補至 512x512。
- 標準化：執行像素值標準化。

驗證集處理：

- 僅執行 512x512 尺寸調整與標準化，不進行隨機擴增，以確保評估的一致性。

(2) 模型架構與訓練配置 (ResNet50 as Backbone)

- 訓練策略：半微調 (Semi-Fine-tuning)，解凍 ResNet50 的 Layer 1-4 進行權重更新，讓模型針對肋骨的邊緣細節進行深度適應，希望能提升分割精確度
- 模型架構：U-Net 分割框架，搭載預訓練的 ResNet50 編碼器，輸出層使用 Softmax2d。在影像縮放的過程中，細微的空間資訊容易流失。透過 U-

Net 的跳躍連接能將編碼器保留的高解析度細節，直接傳給解碼器。這讓模型在生成分割結果時，能參考最原始的邊緣資訊，確保肋骨輪廓精確且不失真。

- 損失與指標：採用 Dice Loss 損失函數；以 IoU (閾值 0.5) 作為評估標準。
- 優化器：Adam (學習率 $1e-4$)。
- 排程器：ReduceLROnPlateau (損失停滯 3 代後，將學習率乘以 0.1)。
- 模型選擇：自動儲存驗證集 IoU 分數最高的權重作為最佳模型。

(3) 測試集評估

標籤映射 (Label Mapping)：將原始標籤映射至預定義類別（肋骨、背景）。

前處理與驗證集一致

執行模型推論並計算 IoU 與 Dice Loss。

(4) 錯誤過濾與品質控管


篩選出 Dice 或 IoU 低於 0.7 的樣本，設定此門檻為「不及格」的影像透過原圖、預測、疊圖、真實答案比較，將抽象的分數轉換為直觀的解剖影像，幫助開發者像醫師一樣進行病案討論。

用顏色標記出偽陽、偽陰，判斷是否需要增加特定光照條件的訓練資料，或是調整模型的敏感度。


三、結果

(1) 數據可用性驗證

為確保模型接收到高品質的輸入資訊，先做資料視覺化。如下圖所示，系統能成功讀取胸部 X 光原圖，並配對對應的肋骨遮罩。



(2) 訓練過程中，訓練集、驗證集分別的 Dice Loss、IoU 的視覺呈現圖



模型在 30 Epoch 中 Dice Loss 的變化趨勢，在訓練與驗證中快速收斂，顯示該架構配合遷移學習能非常迅速地掌握肋骨的基本特徵，約在第 20 個 Epoch 後，曲線趨於穩定。其中發現，驗證損失始終低於訓練損失，可能因為訓練集啟用了隨機擴增，任務較難；而驗證集是純淨資料且資料量小，任務相對簡單。

而在模型分割精確度 (IoU) 趨勢圖驗證集的 IoU 最終穩定在 0.89 左右，也可發現 ReduceLROnPlateau 後期適時降低學習率有助於模型進行權重微調。


(3) 測試集結果

測試集平均 Dice Loss: 0.0559

測試集平均 IoU Score: 0.8968

Bad Case 診斷


[BAD] VinDr_RibCXR_val_004.png - Dice=0.7853, IoU=0.6465



假陽性區塊較為分散，可能是因為原始影像背景較白。在進行影像銳利化後，肋骨間的縫隙變模糊，導致模型發生邊際溢出，將肋骨間隙也判斷為肋骨區域。

假陰性區塊多出現在影像的最上方與最下方，可發現肺底部與腹部器官重疊，使 X 光穿透率降低，導致肋骨影像極度模糊。模型在此處無足夠的特徵信心，因此選擇不進行預測。

[BAD] VinDr_RibCXR_val_010.png - Dice=0.8124, IoU=0.6840



假陽性區塊可發現在下方有大面積誤判，可能是因為該曲靠近中央縱膈腔處，模型誤將此陰影當成了肋骨的延伸。

假陰性部分多在中段內側可能是因為該處受血管影覆蓋，導致肋骨的線性紋理被模糊掉，模型對於該區域的肋骨存在機率判定降低，而最下方的藍色塊顯示模型完全漏掉了邊緣的細小肋骨，可能是因為邊緣對比度過低

四、結論

本研究初步建立肋骨自動分割系統，透過實驗驗證，測試集表現與訓練過程中的驗證分數趨於一致，顯示模型在現有資料分布下達成了初步的穩定性。儘管有小規模資料限制，但透過 ResNet50 半微調與資料擴增等技術手段，嘗試彌補樣本量不足的問題，使模型初步具備了辨識跨設備、跨患者肋骨特徵的可能性。

在錯誤分析仍發現模型在處理複雜解剖構造時存在明顯侷限，包含結構重疊、對比度較低的區域，仍可透過優化前處理強化低對比區域的辨識率或精進模型架構引入空間注意力機制，嘗試讓模型能更專注於肋骨特徵，以增加分割能力。